基于逻辑回归与 TF-IDF 的中文情感分类器：以豆瓣影评与《骆驼祥子》为例

一、研究问题与背景

在自然语言处理（NLP）的众多分支中，情感分析（Sentiment Analysis）是一项兼具理论价值与现实意义的任务。在如今的社交媒体与电商平台上，每天都会有用户产生出海量带有主观色彩的文本。所以能准确识别这些文本背后的情感倾向，对于产品反馈分析、舆情监控等都有着至关重要的作用。

然而，中文的情感表达极为复杂。除了基础的词汇组合，中文常常包含隐喻、反讽、双重否定以及大量网络流行语，这给机器理解文本带来了巨大的挑战。本次作业旨在构建一个二元分类器，探讨传统的机器学习模型——即结合 TF-IDF 特征与逻辑回归（Logistic Regression）的模型，在面对复杂中文短评时的表现、内在局限性，并将其应用于长篇小说中，观察其在宏观叙事中的预测模式。

二、数据集与标签定义

本次实验采用的数据集来源于课程提供的豆瓣影评 JSON 文件。该原始数据包含了 1 星至 5 星共五个等级的评分。为了保证二分类任务（正面 vs 负面）的纯粹性，避免中性评价对模型决策边界的干扰，我仅提取了评分极端的数据：将 5 星评价定义为正面情感（标签设为 1），将 1 星评价定义为负面情感（标签设为 0），舍弃了 2、3、4 星的中立或模糊评价。

在数据预处理阶段，由于原始文本中可能包含大量无意义的符号与空格，我进行了严格的清洗。随后，使用 OpenCC 库将评论统一转换为简体中文，并使用 jieba 分词库对文本进行分词处理。为了让模型能够学习并输出概率，最后按照 80%训练集与 20%测试集的比例，使用固定的随机种子（random_state=42）对数据进行了划分，以保证实验的可重复性。

三、特征工程与模型训练

在特征提取环节，我选择了经典的 TF-IDF（词频-逆文档频率）算法。相较于单纯计算词频，TF-IDF 能够很好地平衡词汇在单条评论中的重要性与其在整个语料库中的普遍性。如果“好看”这个词在某条评论中出现很多次，TF-IDF 会给予它高权重；但如果“好看”在几乎所有评论中都会出现，它的权重就会被拉低。我最终提取了权重最高的前 2000 个词作为特征向量，这足以涵盖影评中最具代表性的情感词汇。

在模型选择上，我使用了 Logistic Regression（逻辑回归）。逻辑回归虽然结构简单，但在高维稀疏的文本特征空间中表现非常稳定。而且其基于线性边界的分类逻辑在文本分类任务中具备极强的可解释性，非常适合用于直观地观察词汇特征对情感判定的影响。

四、测试集结果与错误分析

模型在 20%的测试集上取得了 0.8834 的较好准确率。通过查看混淆矩阵与 error_analysis.csv 文件，我挑选出以下三类典型的错误样本进行剖析：

错例 1：否定词与分词导致的误判

文本：“真心是没悬念没情节没爆点没……的都市猎杀主题处女作，看完表示好没趣，郁闷地睡觉了”

分析：该评论实际上是一星差评，但模型却将其预测为正面。我推测，这是因为 jieba 分词将“好没趣”错误地切分成了“好”与“没趣”。模型只捕捉到了“好”这个强正向词，却没有理解“好没趣”在此处是强烈的反语，也忽略了前后“没情节”、“没爆点”营造的负面语境。这暴露了词袋模型（Bag of Words）完全忽略语序和句法结构的致命缺陷。

错例 2：反讽与局部词汇干扰

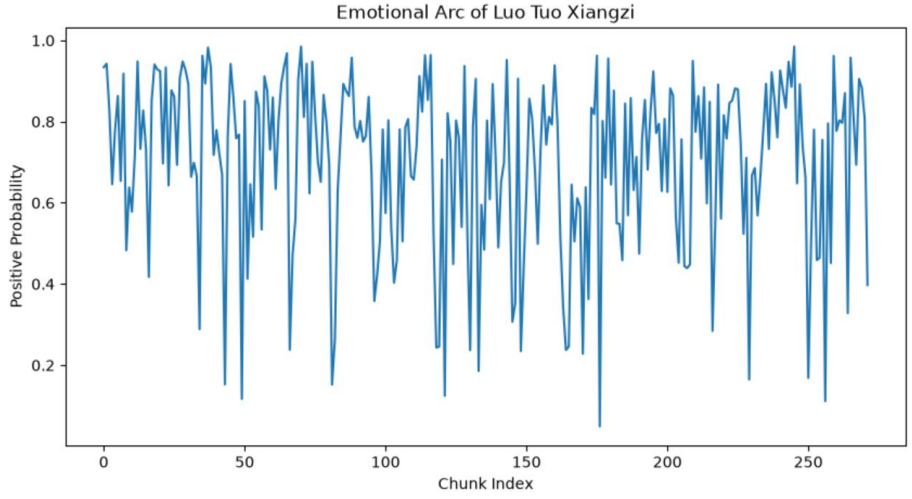
文本：“这电影拍得太好了，好得我中间睡了两个小时”

分析：实际为差评，但预测却为好评。模型只看到了“太好了”这一正向特征，却无法理解人类语言中的反讽修辞。这说明基于统计的词频特征无法捕捉文本的深层语义。

错例 3：长句与词汇权重的稀释

文本：“这本书教会了我一个很久的道理，结束前不要下判断。读到在沃尔特和莎拉电话复习笑话前……一本让我看完三分之二的时候就想扔掉的书……”

分析：这条实际上是用先抑后扬来表达对书的高度赞扬，但被预测为差评。模型显然是被后半段的“扔掉”一词赋予了过高的负面权重，未能理解作者表达的“读完才懂得它的好”的转折逻辑。对于较长的文本，模型往往只记住最强烈的“情绪刺”，而忽略了文本的整体落脚点。



五、模型在新文本上的应用：以《骆驼祥子》为例

为了检验分类器的泛化能力，我将老舍的《骆驼祥子》全文按每 500 字左右切分为 272 个片段，输入模型计算每个片段为“正面情感”的概率，并绘制了情感曲线（见上图）。

从图中可以看出，小说的情感概率在 0.1 到 1.0 之间呈现极度剧烈的震荡。我原本预期会看到一条随着祥子命运沉沦而平滑下降的曲线，但现实是锯齿状的。经过反思，我得出以下原因：

第一，固定 500 字的机械切分，打断了小说原有的叙事连贯性。上一段可能是祥子在北平秋天的阳光下拉车，下一段可能紧接着就是被大兵抓走或虎妞逼婚，导致负向词激增。

第二，逻辑回归模型缺乏长时记忆，它只看眼前的这 500 字里包含什么词汇。

第三，尽管曲线震荡，但结合小说情节来看，这种剧烈的震荡恰恰反映了老舍笔下祥子“三起三落”的悲剧命运——每次刚有一点希望，如：买到车、遇到曹先生，立刻就被现实狠狠击碎。在文本的后 30 个片段，概率跌破 0.2 的频次明显增加，这也侧面印证了模型对悲剧结局的敏锐捕捉。

六、局限性与反思

通过本次实验，我深刻认识到了传统机器学习模型的局限性。首先，TF-IDF 与逻辑回归的组合属于线性模型，无法理解上下文，双重否定和反讽，并且逻辑回归无法结合上下文语境；其次，文本截断切分破坏了文学作品的宏观叙事结构。此外，短文本（如豆瓣评论）和长文本（如小说片段）在特征分布上存在巨大差异，跨任务直接应用时，模型很容易产生误判。